

Problema 1 – Classificação de tipos de feijão usando descritores de forma.

Imagine que você e sua equipe trabalham para uma empresa de tecnologia que presta consultoria na área de Inteligência Artificial para o setor do agronegócio. Seu Tahin, dono de uma fazenda na Índia, contratou um hardware que realiza a colheita dos grãos de feijão de forma automática, agilizando assim, o processo de colheita durante a safra do produto. No entanto, o hardware desenvolvido não consegue fazer a distinção entre as classes de feijão existentes (Seker, Barbunya, Bombay, Cali, Dermosan, Horoz e Sira) e, por isso, houve a necessidade do desenvolvimento de uma aplicação para este propósito.

O time responsável pelo software pensou em várias estratégias capazes de separar os grãos de feijão. Ao final do brainstorming, ficou decidido em usar uma câmera de alta resolução para captura de imagens dos grãos que foram coletados pelo hardware. Em seguida, foram utilizadas técnicas da área de Visão Computacional, subárea da Inteligência Artificial que trabalha com imagens/vídeos, para a extração de características de forma e dimensão destes grãos. Por fim, estas características seriam encaminhadas para uma Rede Neural do tipo feedforward responsável pela classificação dos grãos de feijão nas sete classes existentes (mencionadas acima).

Uma vez decididas as tarefas, sua equipe ficou responsável por treinar e validar uma Rede Neural que seja capaz de receber as características extraídas e prever a sua respectiva classe. No entanto, existem várias arquiteturas de Redes Neurais e hiperparâmetros que precisam ser ajustados conforme a aplicação.

Neste problema, vocês utilizarão uma base de dados pública disponível na plataforma do Kaggle através do link: <https://www.kaggle.com/datasets/muratkokludataset/dry-bean-dataset>. Após o download da base de dados, você já pode começar a sua implementação da Rede Neural para classificação de dados estruturados. Lembrando que você precisa validar o desempenho do modelo criado, portanto, separe a base de dados em conjunto de

treino e teste usando o método holdout. A seguir, algumas informações sobre a base de dados.

Quantidade de grãos capturados: 13.611 grãos.

Quantidade de características extraídas: 16 características, sendo 12 de dimensão e 4 de forma.

Mais informações sobre a base de dados, podem ser obtidas através do link disponibilizado acima. **Diante disso, como vamos ajudar o seu Tahin no desenvolvimento desta solução inteligente usando conceitos e técnicas de Redes Neurais?**